



1η Σειρά Ασκήσεων

Ονοματεπώνυμο Α.Μ.

Μαλαμάς Νικόλαος: 2020030180

Πατσέα Ιωάννα-Γεωργία: 2020030033


Ομάδα 11

Θέμα 1: Principal Component Analysis (PCA)

Σε αυτή την άσκηση, χρησιμοποιήθηκε η μέθοδος Principal Component Analysis (PCA). Στο Α' Μέρος, η μέθοδος εφαρμόστηκε πάνω σε ένα σύνολο δεδομένων που περιγράφουν καλοήθεις και κακοήθεις όγκους στο στήθος, ενώ στο Β' Μέρος αξιοποιήθηκε πάνω σε ένα μεγαλύτερο σύνολο δεδομένων, 5000 εικόνων προσώπων.


Μέρος 1

Αρχικά, εκτυπώνοντας τα πρώτα 100 δείγματα του dataset συναρτήσε των feature 1, feature 2 λαμβάνουμε:




Σχήμα 1: 100 Data samples in 2D, using the 1st and 2nd feature

Ενώ, εκτυπώνοντας τα ίδια 100 δείγματα συναρτήσε των feature 5 και feature 10 λαμβάνουμε:



Σχήμα 2: 100 Data samples in 2D, using different features

α') Για την εφαρμογή του standardization (κανονικοποίηση με μέση τιμή μηδέν και διασπορά 1) χρησιμοποιήθηκε ο τύπος $\hat{x}_i = \frac{x_i - \mu}{\sigma}$, όπου μ η μέση τιμή του x και σ η διασπορά του. Έτσι, δημιουργήθηκε η συνάρτηση 'featureNormalize' και σχεδιάστηκαν τα κανονικοποιημένα δείγματα τα οποία προκύπτουν ως εξής:



Σχήμα 3: Normalized Data Samples in 2D, using the 1st and 2nd feature


Αφότου εφαρμόζεται το Standardization στα δείγματα, μπορεί εύκολα να γίνει αντιληπτό ότι στο νέο γράφημα που σχεδιάζεται, οι άξονες είναι περιορισμένοι σε ένα πολύ μικρότερο εύρος τιμών ($y : [-2.5, 2.5]$, $x : [-2, 4]$) συγκριτικά με αυτούς των μη κανονικοποιημένων δειγμάτων ($y : [10, 28]$, $x : [5, 25]$). Αυτό είναι ενδεικτικό της εφαρμογής κανονικοποίησης

πάνω στα δείγματα, καθώς αυτά παρουσιάζουν διασπορά ίση με 1, με αποτέλεσμα να μην “απλώνονται” τόσο στον 2D χώρο.

Ακόμη, παρατηρείται ότι τα κανονικοποιημένα δείγματα είναι “κεντραρισμένα” γύρω από διαφορετικές τιμές των δύο αξόνων, σε σχέση με τα αρχικά, κάτι το οποίο μπορεί να αιτιολογηθεί από το γεγονός ότι, κατά την εφαρμογή του Standardization, η μέση τιμή αφαιρέθηκε από κάθε δείγμα.

- β') Για τον υπολογισμό των κύριων συνιστωσών του αλγορίθμου PCA προστέθηκε ο κώδικας στην συνάρτηση *'myPCA'* στην οποία αρχικά δημιουργήθηκε ο πίνακας συνδιασποράς κανονικοποιημένων δεδομένων με βάση τον τύπο $\Sigma = \frac{1}{m}X^T X$, ενώ έπειτα με την συνάρτηση του Matlab, *eig()* υπολογίστηκαν οι ιδιοτιμές και τα ιδιοδιανύσματα του.

Σχεδιάστηκαν οι κύριες συνιστώσες που υπολογίστηκαν παραπάνω μαζί με τα αρχικά δείγματα:



Σχήμα 4: Normalized Samples and principal components

Αναφορικά με την μορφή των δύο κύριων συνιστωσών που παρουσιάζονται στο γράφημα, χρειάζεται κανείς να μελετήσει τον κώδικα της συνάρτησης *'myPCA'*. Η συγκεκριμένη συνάρτηση επιστρέφει, μεταξύ άλλων, τα ιδιοδιανύσματα του πίνακα συνδιασποράς των κανονικοποιημένων δεδομένων, διατεταγμένα με σειρά από το πιο “σημαντικό” προς το λιγότερο σημαντικό. Το Matlab υπολογίζει τα παραπάνω και τα εκχωρεί στην μεταβλητή *eigvecs*, την οποία ανοίγοντάς στο περιβάλλον *'Variables'* του Matlab παρατηρούνται τα εξής δεδομένα:

$$eigvecs = \begin{pmatrix} -0.7071 & 0.7071 \\ -0.7071 & -0.7071 \end{pmatrix}$$

Μετά την κατάταξη ως προς την σημαντικότητα που αναφέρθηκε παραπάνω, ερμηνεύουμε τις στήλες της μεταβλητής *eigvecs* ως τα principal components που λαμβάνουμε υπόψιν.

Έτσι, η πρώτη PC είναι η $\begin{pmatrix} -0.7071 \\ -0.7071 \end{pmatrix}$, ενώ η δεύτερη είναι η $\begin{pmatrix} 0.7071 \\ -0.7071 \end{pmatrix}$.

Λαμβάνοντας υπόψιν όλα τα παραπάνω μπορεί κανείς να ερμηνεύσει τόσο την ορθογωνιότητα μεταξύ των δύο κύριων συνιστωσών όσο και την φορά και το μέτρο τους. Η πρώτη κύρια συνιστώσα (κόκκινο βέλος) έχει μεγαλύτερο μέτρο, φορά που ορίζεται από δύο αρνητικές συντεταγμένες ($\begin{pmatrix} -0.7071 \\ -0.7071 \end{pmatrix}$), ενώ η δεύτερη (μπλέ βέλος) μικρότερο μέτρο και φορά που ορίζεται από θετική τετμημένη και αρνητική τεταγμένη ($\begin{pmatrix} 0.7071 \\ -0.7071 \end{pmatrix}$).

γ') Η συνεισφορά κάθε κύριας συνιστώσας στην συνολική διακύμανση δίνεται από τον τύπο:

$$Var(PC_i) = \frac{\lambda_i}{\sum_{j=1}^L \lambda_j},$$

όπου λ_i η ιδιοτιμή της i -οστής κύριας συνιστώσας, και υπολογίστηκε στον κώδικα στις εξής γραμμές:


```
% Calculate the Explained Variance
ExplainedVar=[eigvals(1)./sum(eigvals) eigvals(2)./sum(
    eigvals)];
fprintf(' Explained Variance(1st PC = %f) (2nd PC = %f)\n',
    ExplainedVar(1), ExplainedVar(2));
```

Έτσι, στο command prompt του Matlab εκτυπώνονται οι εξής τιμές:

```
Explained Variance(1st PC = 0.687891) (2nd PC = 0.312109)
```


Ακόμη, υλοποιήθηκε η συνάρτηση *'projectData'*, ώστε το αρχικό δυσδιάστατο set δεδομένων να προβάλλεται στην μια διάσταση, με βάση τον τύπο $\mathbf{z}_i = \mathbf{U}^T \mathbf{x}_i$.

Παρουσιάζεται η προβολή των δειγμάτων στον μονοδιάστατο χώρο:



Σχήμα 5: PCA of Breast Cancer Dataset


- δ') Μετά την προβολή στον μονοδιάστατο χώρο τα αρχικά δεδομένα ανακτώνται προβάλλοντάς τα πάνω σε όλες τις κύριες συνιστώσες χρήσει του μετασχηματισμού $x_{rec} = Uz$ ο οποίος υπολογίζεται εντός της συνάρτησης 'recoverData'. Τελικά, τα ανεκτημένα δεδομένα χρησιμοποιώντας μόνο την πρώτη κύρια συνιστώσα ανακτώνται στον δυσδιάστατο χώρο, όπως φαίνεται στο παρακάτω γράφημα:




Σχήμα 6: PCA sample projections

Παρατηρείται ότι χρησιμοποιώντας μόνο την πρώτη κύρια συνιστώσα λαμβάνεται ένα ατελές μέτρο διαχωρισμού των δύο κλάσεων, καθώς προβολές των δειγμάτων της κόκκινης κλάσης αναγνωρίζονται ως δείγματα της άλλης κλάσης. Συνεπώς, δεν υπάρχει πλήρης διαχωρισμός των δύο κλάσεων.

- ε') Το πείραμα επαναλήφθηκε, εφαρμόζοντας ξανά τον αλγόριθμο PCA, αλλά λαμβάνοντας αυτή την φορά υπόψιν το πλήρες διάνυσμα χαρακτηριστικών. Παρακάτω επισυνάπτεται σε κοινό γράφημα τα δείγματα που παρουσιάζουν τη μεγαλύτερη διακύμανση με τις δύο principal components και εν συνεχεία, σε διαφορετικό γράφημα, η προβολή των δειγμάτων πάνω σε αυτές.



Σχήμα 7: Δείγματα με μεγαλύτερη διακύμανση




Σχήμα 8: Προβολή των δειγμάτων

Παρατηρούμε ότι αφού χρησιμοποιήσουμε όλο το διάνυσμα χαρακτηριστικών, οι δύο PC αλλάζουν τόσο μορφολογικά (μέτρο) όσο και στη θέση τους πάνω στο γράφημα (φορά και μεταξύ τους γωνία). Αυτό συμβαίνει επειδή, χρησιμοποιώντας περισσότερες PCs, η Explained Variance των πρώτων δύο Principal Components μειώνεται, μιας και ο παρονομαστής του τύπου $Var(PC_i) = \frac{\lambda_i}{\sum_{j=1}^L \lambda_j}$ αυξάνεται. Έτσι, η διαχωριστική ικανότητα των πρώτων δύο κύριων συνιστωσών μειώνεται, με αποτέλεσμα να προκύπτουν λάθος συμπεράσματα περί του σε ποιά κλάση ανήκει το κάθε δείγμα.


Μέρος 2

ε') Με την συνάρτηση 'displayData()' που δίνεται σχεδιάστηκαν τα πρώτα 100 πρόσωπα:



Σχήμα 9: The first 100 faces

ζ') Στην συνέχεια, όπως και στο πρώτο μέρος, με την συνάρτηση 'featureNormalize()' εφαρμόστηκε standardization, ενώ με την 'myPCA()' υπολογίστηκαν οι 36 κύριες συνιστώσες όπου και σχεδιάστηκαν:




Σχήμα 10: The top 36 eigenvectors found

Είναι εμφανές ότι, μειώνοντας τα προς εκτύπωση πρόσωπα, άρα και τις κύριες συνιστώσες που

χρησιμοποιούνται, το τελικό αποτέλεσμα που έχει επισυναφθεί παραπάνω, είναι σαφώς μικρότερης ακρίβειας σε σύγκριση με το αρχικό.

Αυτό είναι αναμενόμενο, καθώς από τη στιγμή που λιγότερη πληροφορία αξιοποιείται για την ανάκτηση των δεδομένων μας, το αποτέλεσμα θα είναι μια λιγότερο πιστή αναπράσταση τους.


- η') Αφού υλοποιήθηκε με τον κατάλληλο κώδικα, η `'projectData()'` αξιοποιήθηκε για την μείωση της διάστασης των δειγμάτων χρήσει των πρώτων 100 κύριων συνιστώσων.
- θ') Αφότου υλοποιήθηκε η συνάρτηση ανάκτησης των αρχικών δειγμάτων `'recoverData()'`, χρησιμοποιήθηκε για την ανάκτηση τους στον πολυδιάστατο χώρο. Ακολούθως, πραγματοποιήθηκε η σχεδίασή των ανεκτημένων δειγμάτων με τα αρχικά σε κοινό plot:




Σχήμα 11: $K=100$

Παρατηρούμε ότι για $K=100$, πρώτες κύριες συνιστώσες, τα ανεκτημένα πρόσωπα δεν είναι ακριβής αναπράσταση των αρχικών, που σημαίνει ότι το K είναι ανεπαρκώς μικρό, αφού δεν μπορεί να δώσει όλη την πληροφορία για τις εικόνες.


Εν συνεχεία, επαναλήφθηκε η παραπάνω διαδικασία για $K=10$, 50 και 200 κύριες συνιστώσες, δίνοντας τα εξής αποτελέσματα:



Σχήμα 12: $K=10$



Σχήμα 13: $K=50$



Σχήμα 14: $K=200$

Γίνεται εμφανές ότι όσο μεγαλύτερο το K τόσο περισσότερη πληροφορία έχουμε άρα και τόσο πιο ευκρινή θα είναι τα πρόσωπα στις εικόνες που σχεδιάζονται.

Είναι σημαντικό να σημειωθεί ότι, προκειμένου να εκτυπώνονται με ομαλές διαστάσεις τα πρόσωπα σε κάθε grid, θα πρέπει στη συνάρτηση *displayData()* να δίνεται σαν όρισμα το πλάτος του κάθε grid και χρησιμοποιώντας αυτό, η συνάρτηση να καθορίζει και το ύψος του. Αυτό επιτεύχθηκε στον κώδικα, δίνοντας σαν όρισμα πλάτους το $\frac{1}{10}$ του ελάχιστου αριθμού των κύριων συνιστωσών, ώστε να είναι 'δίκαιη' η σύγκριση ποιότητας των εικόνων. Δηλαδή, κάθε grid, για δεδομένο K , εκτυπώνεται με πλάτος $\frac{K}{10}$ και ύψος 10, καθώς στην *displayData()*, αυτό ορίζεται ως $height = \frac{n}{width}$.

Θέμα 2: Σχεδιάστε ένα ταξινομητή LDA (Linear Discriminant Analysis)

1. Αρχικά, βρίσκουμε τον πίνακα σκέδασης S_w ως:

$$S_w = \sum p_i \Sigma_i = p_A \Sigma_A + p_B \Sigma_B = 0.4 \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix} + (1 - 0.4) \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} 2.4 & 1 \\ 1 & 2.6 \end{pmatrix}$$

και στη συνέχεια βρίσκουμε τον αντίστροφο του S_w^{-1} σύμφωνα με τον τύπο που δίνεται:

$$S_w^{-1} = \frac{1}{2.4 \cdot 2.6 - 1 \cdot 1} \begin{pmatrix} 2.4 & 1 \\ 1 & 2.6 \end{pmatrix} = \frac{1}{5.24} \begin{pmatrix} 2.4 & 1 \\ 1 & 2.6 \end{pmatrix}$$

Τελικά, το διάνυσμα προβολής $\mathbf{w}$:

$$\mathbf{w} = S_w^{-1}(\mu_A - \mu_B) = \frac{1}{5.24} \left(\begin{pmatrix} 0 \\ 2 \end{pmatrix} - \begin{pmatrix} 2 \\ 0 \end{pmatrix} \right) = \frac{1}{5.24} \begin{pmatrix} -7.2 \\ 6.8 \end{pmatrix}$$

2. Για την εύρεση των προβολών των δύο διανυσμάτων x_A και x_B , χρησιμοποιούμε τον τύπο $\hat{y} = \frac{\mathbf{w}^T \mathbf{x}}{\|\mathbf{w}\|}$, όπου το μέτρο του διανύσματος $\mathbf{w}$ βρίσκεται ως:

$$\|\mathbf{w}\| = \sqrt{\left(\frac{1}{5.24}\right)^2 (-7.2)^2 + \left(\frac{1}{5.24}\right)^2 (6.8)^2} = \frac{1}{5.24} \sqrt{98.08} \approx \frac{10}{5.24}$$

Έτσι, για τις προβολές των x_A και x_B πάνω στο $\mathbf{w}$, λαμβάνουμε ότι:

$$\hat{y}_A = \frac{w^T x_A}{\|w\|} = \frac{\frac{1}{5.24} \begin{pmatrix} -7.2 & 6.8 \end{pmatrix} \begin{pmatrix} 1 \\ 3 \end{pmatrix}}{\frac{1}{5.24} 10} = \begin{pmatrix} -0.72 \\ 2.04 \end{pmatrix}$$


$$\hat{y}_B = \frac{w^T x_B}{\|w\|} = \frac{\frac{1}{5.24} \begin{pmatrix} -7.2 & 6.8 \end{pmatrix} \begin{pmatrix} 3 \\ -1 \end{pmatrix}}{\frac{1}{5.24} 10} = \begin{pmatrix} -2.16 \\ 0.68 \end{pmatrix}$$

Θέμα 3: Linear Discriminant Analysis (LDA) vs PCA

Ο σκοπός της άσκησης είναι η εφαρμογή Linear Discriminant Analysis για τη μείωση της διάστασης ενός feature vector και η σύγκριση των αποτελεσμάτων με τη μέθοδο PCA.

Μέρος 1

- α') Αρχικά, Φορτώθηκαν τα δείγματα που δίνονται από το αρχείο 'data\data2.mat'.
- β') Στην συνέχεια έγινε standardization (κανονικοποίηση με $\mu=0$ και $\sigma=1$) με την βοήθεια της συνάρτησης 'featureNormalize()' που δημιουργήθηκε στο θέμα 1 και σχεδιάστηκαν με διαφορετικό χρώμα τα δείγματα κάθε κλάσης στην ίδια εικόνα όπως φαίνεται στο παρακάτω σχήμα.




Σχήμα 15: Normalized samples of two different classes

- γ') Δημιουργήθηκε η συνάρτηση 'fisherLinearDiscriminant()' έτσι ώστε να υλοποιεί τον αλγόριθμο LDA για προβλήματα δύο κλάσεων.
- Αρχικά, υπολογίστηκαν οι μέσες τιμές και το covariance των δύο κλάσεων, ενώ ταυτόχρονα με βάση την θεωρία και τον τύπο

$$S_w = \sum_{i=1}^C P_i \Sigma_i$$


βρέθηκαν οι μέσες τιμές και ο εσωτερικός πίνακας διασποράς των κλάσεων αυτών.

- δ') Έπειτα, προστέθηκε κώδικας στην συνάρτηση 'projectDataLDA()' ώστε τρέχοντάς την να δημιουργούνται δείγματα μειωμένης διάστασης (1D).
- ε') Ομοίως, συμπληρώθηκε ο κατάλληλος κώδικας για την 'recoverDataLDA()', προκειμένου να γίνει ανακατασκευή των δειγμάτων μειωμένης διάστασης στον 2D χώρο, προβάλλοντας τα πάνω στην κατεύθυνση του διανύσματος προβολής LDA. Σχεδιάστηκαν πάνω στην ίδια εικόνα τα δείγματα μειωμένης διάστασης μαζί με τα αρχικά όπως φαίνεται παρακάτω:



Σχήμα 16: LDA on example dataset

- ζ') Εφαρμόστηκε η ίδια διαδικασία μείωσης διάστασης με την μέθοδο PCA όπως έγινε και στο θέμα 1. Παρακάτω σχεδιάστηκαν οι προβολές των δειγμάτων που προκύπτουν από την μέθοδο αυτή.



Σχήμα 17: PCA on example dataset


Παρατηρείται ότι, η ευθεία προβολών που υπολογίζεται από κάθε μέθοδο είναι διαφορετική, με αυτήν της LDA να έχει αρνητική κλίση και αυτήν της PCA θετική.

Αυτό συμβαίνει, γιατί κάθε μια από τις μεθόδους υπολογίζει μια διαφορετική ευθεία που 'θεωρεί' ως βέλτιστη για να προβληθούν πάνω σε αυτή τα δείγματα των δύο κλάσεων, με αποτέλεσμα να λαμβάνουμε δύο διαφορετικές ευθείες.

Μέρος 2


Σε αυτό το μέρος εφαρμόζεται ο αλγόριθμος LDA στην βάση Iris.

- α') Για αρχή, φορτώθηκαν τα δείγματα Iris δημιουργώντας έτσι 150 δείγματα.
- β') Όπως και προηγουμένως, εφαρμόστηκε standardization στα δείγματα και σχεδιάστηκαν τα 2 πρώτα χαρακτηριστικά σε ένα 2D γράφημα χρησιμοποιώντας ξεχωριστά χρώματα για κάθε κλάση.



Σχήμα 18: First 2 features

- γ') Δημιουργήθηκε η συνάρτηση 'myLDA()' στην οποία με βάση την θεωρία υπολογίστηκαν οι prior πιθανότητες, οι μέσες τιμές, ο ολικός μέσος, ο πίνακας σκέδασης S_w , ο πίνακας S_b και ο πίνακας $S_w^{-1}S_b$.
- δ') Τέλος, εφαρμόστηκαν τα διανύσματα προβολής που υπολογίστηκαν από την συνάρτηση 'myLDA()' πάνω στα αρχικά δείγματα χρησιμοποιώντας την συνάρτηση 'projectDataLDA()' μειώνοντας έτσι τη διάστασή τους σε 2. Παρακάτω, παρουσιάζεται το γράφημα στο επίπεδο (2D) χρησιμοποιώντας ξεχωριστά χρώματα για τις διαφορετικές κλάσεις:



Σχήμα 19: First 2 features after applying LDA

Παρατηρείται ότι, μετά την κανονικοποίηση και την εφαρμογή του αλγορίθμου LDA, στο τελικό γράφημα υπάρχει σαφής διαχωρισμός μεταξύ των δειγμάτων κάθε κλάσης.

Θέμα 4: Bayes

1. Χρησιμοποιώντας τη μονότονη συνάρτηση $\ln()$, ορίζουμε τις *Discriminant Functions*, οι οποίες μας επιτρέπουν να βρούμε τα όρια απόφασης με τρόπο ισοδύναμο με αυτόν που ορίζει η Bayesian Theory.

$$g_1(\mathbf{x}) = \ln(P(\omega_1|\mathbf{x})) = \ln(P(\mathbf{x}|\omega_1) + \ln(P(\omega_1))) = -\frac{1}{2}(\mathbf{x}-\mu_1)^T \cdot \Sigma_1^{-1} \cdot (\mathbf{x}-\mu_1) + \ln(P(\omega_1)) + c_1$$

και

$$g_2(\mathbf{x}) = \ln(P(\omega_2|\mathbf{x})) = \ln(P(\mathbf{x}|\omega_2) + \ln(P(\omega_2))) = -\frac{1}{2}(\mathbf{x}-\mu_2)^T \cdot \Sigma_2^{-1} \cdot (\mathbf{x}-\mu_2) + \ln(P(\omega_2)) + c_2$$

όπου $c_1 = -\ln(2\pi) - \frac{1}{2}\ln(|\Sigma_1|)$ και $c_2 = -\ln(2\pi) - \frac{1}{2}\ln(|\Sigma_2|)$.

Για την εύρεση των Decision Boundaries, αρκεί να εξισώσουμε τις *Discriminant Functions*:

$$g_1(\mathbf{x}) = g_2(\mathbf{x}) \Leftrightarrow g_1(\mathbf{x}) - g_2(\mathbf{x}) = 0 \stackrel{P(\omega_1|\mathbf{x}) \sim \mathcal{N}(\mu_1, \Sigma_1)}{P(\omega_1|\mathbf{x}) \sim \mathcal{N}(\mu_1, \Sigma_1)} \Leftrightarrow -\frac{1}{2}(\mathbf{x}-\mu_1)^T \cdot \Sigma_1^{-1} \cdot (\mathbf{x}-\mu_1) + \ln(P(\omega_1)) + c_1 - (-\frac{1}{2}(\mathbf{x}-\mu_2)^T \cdot \Sigma_2^{-1} \cdot (\mathbf{x}-\mu_2) + \ln(P(\omega_2)) + c_2) \Leftrightarrow$$

$$(\mathbf{x}-\mu_2)^T \cdot \Sigma_2^{-1} \cdot (\mathbf{x}-\mu_2) - (\mathbf{x}-\mu_1)^T \cdot \Sigma_1^{-1} \cdot (\mathbf{x}-\mu_1) = 2\ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right) - c$$

$$\text{όπου } c = 2(c_1 - c_2) = \ln\left(\frac{|\Sigma_2|}{|\Sigma_1|}\right)$$

Έπειτα από πράξεις, καταλήγουμε ότι:



$$0.14x^2 + 0.20y^2 - 6.66x - 7.25y + 1.11xy = 2\ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right) - c - 32.65$$

Η δεξιά μεριά είναι σταθερή για πακτωμένα $P(\omega_1), P(\omega_2)$ και έτσι, αν τα μεταφέρουμε στην αριστερή μεριά, η εξίσωση είναι της μορφής:

$$ax^2 + by^2 + cx + dy + exy + f = 0$$


που δεν είναι παρά η εξίσωση μιας παραβολής.

2. Χρήσει MATLAB, προκύπτουν οι παρακάτω καμπύλες για τις PDF των δύο κλάσεων:



Σχήμα 20: Οι ισοϋψείς καμπύλες των ΣΚΠ για τις δύο κλάσεις

3. Δεδομένου ότι είχαμε προηγουμένως υπολογίσει τα όρια απόφασης και είχαμε αναγνωρίσει τη μορφή θα έχουν αυτά, τα σχεδιάζουμε για διάφορες τιμές των a-priori πιθανοτήτων, θεωρώντας ότι αυτές συνδέονται με τη σχέση $P(\omega_2) = 1 - P(\omega_1)$.



Σχήμα 21: Τα όρια απόφασης, σχεδιασμένα για διάφορες τιμές των a-priori πιθανοτήτων

Τα σύνορα απόφασης φαίνεται, μέσω των αντίστοιχων γραφημάτων, να ακολουθούν την μορφή παραβολής, ανεξαρτήτως των a-priori πιθανοτήτων των δύο κλάσεων.

Το παραπάνω είναι αναμενόμενο, καθώς και σε θεωρητικό επίπεδο, οι υπολογισμοί που αναγράφηκαν προηγουμένως αποκαλύπτουν ότι η τελική εξίσωση των συνόρων απόφασης ταυτίζεται με αυτήν μιας παραβολής.

Μάλιστα, το δεξί διάγραμμα, δημιουργημένο με την επιλογή 'interp' του MATLAB, μας δίνει τη δυνατότητα να διακρίνουμε τη μορφή κάθε συνόρου, λόγω της έμφασης που δίνεται στις αυξομειώσεις των τιμών του, μέσω του χρωματικού 'κώδικα'.

Δεδομένου ότι οι πίνακες συνδιασποράς των δύο κλάσεων δεν είναι ίσοι σε αυτή την περίπτωση, κατά τους υπολογισμούς, οι όροι $x^T \Sigma_1 x$ και $x^T \Sigma_2 x$, δεν απαλοίζονται, δίνοντας έτσι quadratic χαρακτηριστικά στα σύνορα απόφασης, και όχι linear, όπως θα συνέβαινε στην περίπτωση που αυτοί απαλοίζονταν ($\Sigma_1 = \Sigma_2$).

Τέλος, μπορούμε να πούμε ότι όσο μεγαλώνει η τιμή της a-priori πιθανότητας της κλάσης ω_1 , τα σύνορα απόφαση σαποχτούν όλο και μικρότερες τιμές. Το παραπάνω είναι λογικό, καθώς όπως και στη μονοδιάστατη περίπτωση έυρεσης ορίου απόφασης, αυτό μετακινείται προς τη λιγότερο πιθανή κατανομή (με τη μικρότερη a-priori πιθανότητα). Πιο συγκεκριμένα, επειδή οι καμπύλες των ΣΚΠ διαφέρουν σε ύψος, με αυτήν της ω_2 να είναι λιγότερο ψηλή, όσο η a-priori πιθανότητας της κλάσης ω_1 μεγαλώνει, τα όρια απόφασης τείνουν να την πλησιάσουν, μειώνοντας τις αντίστοιχες τιμές τους στον z άξονα.

4. (α') Δουλεύουμε όμοια με πριν.

Χρησιμοποιούμε και πάλι τη μονότονη συνάρτηση $\ln()$ και ορίζουμε με τη βοήθειά της τις *Discriminant Functions* που προκύπτουν για τις δύο κλάσεις. Προφανώς, η διαδικασία υπολογισμού των ορίων απόφασης ταυτίζεται με αυτήν που ακολουθήσαμε παραπάνω, με τη διαφορά ότι πλέον, λόγω ισότητας των δύο πινάκων συνδιασποράς, οι όροι $x^T \Sigma_1 x$ και $x^T \Sigma_2 x$ απαλοίζονται. Έτσι, λαμβάνουμε την γραμμική πλέον εξίσωση των συντεταγμένων του ορίου απόφασης:


$$-3.12x - 0.62y + 11.56 - 2\ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right) = 0$$

που είναι της μορφής:

$$ax + by + c = 0$$

δηλαδή μια ευθεία.


(β') Χρησιμοποιώντας το MATLAB και τις συναρτήσεις 'contour' και 'surf' παράγουμε γραφικά τις καμπύλες κατανομής πιθανότητας για κάθε κλάση.



Σχήμα 22: Οι ισοϋψείς καμπύλες των ΣΚΠ για τις δύο κλάσεις για $\Sigma_1 = \Sigma_2$

Παρατηρούμε ότι, σε αντίθεση με πριν, που οι πίνακες διασποράς διέφεραν, τώρα οι καμπύλες είναι απλωμένες με πανόμοιο τρόπο στο επίπεδο (λόγω ίδιων πινάκων συνδιασποράς), απλώς σε διαφορετικά σημεία του (λόγω διαφορετικών διανυσμάτων μέσης τιμής).

(γ') Παρακάτω, σχεδιάζουμε τα σύνορα απόφασης, όπως αυτά προέκυψαν γραφικά χρησιμοποιώντας τη συνάρτηση 'plot' του MATLAB, για διάφορες τιμές της a-priori πιθανότητας $P(\omega_1)$.



Σχήμα 23: Τα γραμμικά όρια απόφασης, σχεδιασμένα για διάφορες τιμές των a-priori πιθανοτήτων

Είναι εμφανές ότι τα σύνορα απόφασης είναι ευθείες γραμμές για κάθε τιμή των a-priori πιθανοτήτων των δύο κλάσεων, πράγμα αναμενόμενο, καθώς, όπως σχολιάστηκε νωρίτερα, κατά τον υπολογισμό της εξίσωσης του συνόρου απόφασης, το τελευταίο παρουσίαζε γραμμική συμπεριφορά λόγω της απαλοιφής των $x^T \Sigma_1 x$ και $x^T \Sigma_2 x$ όρων μεταξύ τους ($\Sigma_1 = \Sigma_2$).

Ακόμη, μπορούμε να πούμε πως όσο αυξάνεται η τιμή της a-priori πιθανότητας $P(\omega_1)$, τόσο το σύνορο απόφασης μειώνει την απόστασή του από το κέντρο της κατανομής της κλάσης ω_2 .

Το παραπάνω είναι λογικό, καθώς, όπως παρατηρήθηκε προηγουμένως για την quadratic περίπτωση ορίου απόφασης, αυτό μετατοπίζεται προς την κλάση με τη μικρότερη a-priori πιθανότητα.

Έτσι, για παράδειγμα, όταν $P(\omega_1) = 0.9$, αναμένουμε ότι θα υπάρξει έντονη μετατόπιση του ορίου απόφασης προς τη μεριά της λιγότερο πιθανής ω_2 κλάσης ($P(\omega_1) = 0.1$), όπως και συμβαίνει άλλωστε.

Θέμα 5: Εξαγωγή χαρακτηριστικών και Bayes Classification.

Σε αυτή την άσκηση θα δημιουργηθεί ένας απλός ταξινομητής Bayes, ο οποίος θα κατατάσσει σε κλάσεις, δείγματα ψηφίων αναπαριστούμενα σε εικόνες 28×28 , ανάλογα με το τι αριθμό αυτά αντιπροσωπεύουν.

Τα εν λόγω δείγματα αντλούνται από τα αρχεία *mnist_train.csv* και *mnist_test.csv*, για το training κομμάτι του ταξινομητή και το testing αντίστοιχα.

- α') Το *aspect ratio* υπολογίζεται στην ωμώνυμη Python συνάρτηση ως εξής: Από τον δυσδιάστατο πίνακα *nonzero_pixels*, αναζητούμε, στην πρώτη του γραμμή, την υψηλότερη γραμμή που υπάρχει μη μηδενικό pixel (δηλαδή, στο οποίο έχει γραφτεί κάτι) χρησιμοποιώντας τη συνάρτηση *np.min()*. Αντίστοιχα, στην ίδια σειρά του πίνακα *nonzero_pixels*, βρίσκουμε την χαμηλότερη γραμμή της εικόνας στην οποία αναπαρίσταται το ψηφίο.

Έτσι, με μια απλή αφαίρεση μεταξύ των δύο, μπορεί να υπολογιστεί το ύψος του εικονιζόμενου ψηφίου.



Αντίστοιχη λογική ακολουθείται για την εύρεση του πλάτους του ψηφίου, αυτή τη φορά αναζητώντας το μικρότερο και το μεγαλύτερο στοιχείο της δεύτερης σειράς του *nonzero_pixels* πίνακα.

Τελικά, χρησιμοποιώντας τον ορισμό του *aspectratio*, η συνάρτηση *aspect_ratio* γυρνάει $aspect_ratio = \frac{width}{height}$.

Ακόμη, στο Python Terminal του VSCode, εκτυπώνονται η ελάχιστη και η μέγιστη τιμή του *aspectratio* ως:

```
Maximum aspect ratio before scaling: 2.0
Minimum aspect ratio before scaling: 0.15
```

- β') Για την επιβεβαίωση του ορθού υπολογισμού του *aspectratio* εκτυπώνουμε ένα δείγμα από κάθε κλάση, των ψηφίων 1 και 2, λαμβάνοντας τα εξής bounding boxes:



Σχήμα 24: Δείγματα των δύο κλάσεων με τα αντίστοιχα bounding boxes τους

γ') Για την εφαρμογή της min-max κανονικοποίησης, χρησιμοποιούμε τον τύπο $\hat{x} = \frac{x - \min(x)}{\max(x) - \min(x)}(\max(x) - \min(x)) + \min(x)$ εντός της `'min_max_scaling()'` συνάρτησης. Έτσι, το `aspectratio` περιορίζεται στο διάστημα $[min, max]$, που στην προκειμένη περίπτωση είναι το $[-1, 1]$.

δ') Συμπληρώνοντας τον απαραίτητο κώδικα στην `'train()'`, υπολογίζονται οι a-priori πιθανότητες των κλάσεων C_1 και C_2 . Παρακάτω φαίνονται οι τιμές που αυτές λαμβάνουν, στο Python Terminal του VSCode.

```
P(C1) = 0.5321057601510859
P(C2) = 0.4678942398489141
```

ε') Εν συνεχεία, και πάλι στη συνάρτηση `'train()'`, συμπληρώνουμε τον κώδικα που υλοποιεί την εκπαίδευση του Bayes Classifier.

ς') Έπειτα, υλοποιώντας κατάλληλα την συνάρτηση `'predict()'`, λαμβάνουμε την ικανότητα διαχωρισμού μεταξύ των δύο κλάσεων του ταξινομητή που εκπαιδεύσαμε προηγουμένως. Παρακάτω, η εν λόγω συνάρτηση θα μας φανεί χρήσιμη για τον καθορισμό της ακρίβειας (accuracy) του ταξινομητή.

ζ') Υπολογίζοντας την ακρίβεια ταξινόμησης του Bayes Classifier, λαμβάνουμε την εξής τιμή στο Python Terminal του VSCode.

```
Classification accuracy: 0.9669421487603306
```

Παρατηρούμε ότι ο ταξινομητής μας έχει εξαιρετική ακρίβεια διαχωρισμού μεταξύ δειγμάτων των δύο κλάσεων, καθώς προσεγγίζει τον απόλυτο διαχωρισμό μεταξύ των δύο κλάσεων, αστοχώντας να ταξινομήσει σωστά περίπου 3 ανά 100 δείγματα.

η') Συμπληρώνοντας τη συνάρτηση `'foreground_pixels()'`, μπορούμε χρησιμοποιώντας την συνάρτηση `np.count_nonzero()`, του NumPy, να υπολογίσουμε τα pixels του εικονιζόμενου ψηφίου, που συμμετέχουν στην αναπαράστασή του στην εικόνα. Αργότερα, μέσα στη `main()`, αυτή η συνάρτηση θα αξιοποιηθεί για την προσθήκη ενός επιπλέον χαρακτηριστικού στον ταξινομητή.


- θ') Με σκοπό την προσθήκη ενός ακόμη χαρακτηριστικού στον ταξινομητή, υλοποιούμε κατάλληλα τη συνάρτηση `calculate_centroid()`, λαμβάνοντας όλα τα pixels της εικόνας, το κέντρο των δύο διαστάσεων της και τελικά υπολογίζοντας το "Κέντροειδές" της .
- ι') Επαναλαμβάνοντας τη διαδικασία, προσθέτουμε και το ψηφίο 0, τόσο στην εκπαίδευση του ταξινομητή, μέσω της γραμμής:

```
# Get samples from the selected digits only
df_train = df_train[df_train['label'].isin([0, 1, 2])]
```

όσο και στη φάση δοκιμής του, μέσω της γραμμής:

```
# Get samples from the selected digits only
df_test = df_test[df_test['label'].isin([0, 1, 2])]
```

οι οποίες, επί της ουσίας, λαμβάνουν υπόψη τα ψηφία 0, 1 και 2 από τις κλάσεις ψηφίων του δατασετ. αλλάζουμε τον κώδικα



Σχήμα 25: Δείγματα των τριών κλάσεων με τα αντίστοιχα bounding boxes τους

Εκτυπώνοντας ξανά το υπολογιζόμενο accuracy του ταξινομητή, λαμβάνουμε την εξής τιμή στο Terminal του VSCode:

```
Classification accuracy: 0.7155963302752294
```

Ενώ, για τις a-priori πιθανότητες που αντιστοιχούν σε κάθε κλάση:

```
P(C1) = 0.32093619749919844
P(C2) = 0.3613337608207759
P(C3) = 0.31773004168002567
```

Σχετικά με την ακρίβεια του ταξινομητή μετά την προσθήκη της 3ης κλάσης είναι εμφανής η πτώση της ακρίβειάς του.

Αυτό είναι αναμενόμενο καθώς η αύξηση του αριθμού των κλάσεων οδηγεί σε περισσότερες επικαλύψεις μεταξύ των τελευταίων με αποτέλεσμα να δυσχεραίνεται η ικανότητα αναγνώρισης μεταξύ των δειγμάτων τους.

Ένας ακόμη παράγοντας που μπορεί να συμβάλλει στην αστοχία που παρατηρήσαμε είναι ότι το 0 και το 2, επειδή παρουσιάζουν παρόμοια καμπυλότητα μεταξύ τους, αυξάνει την πιθανότητα να μπερδευτεί ο ταξινομητής σε σχέση με το αν είχε να αναγνωρίσει μόνο μεταξύ του 1 και του 2, τα οποία διαφέρουν πολύ μορφολογικά.

Θέμα 6: Minimum risk

Με το κριτήριο ελαχιστοποίησης μέσου ρίσκου:

$$l_1 = \lambda_{11}P(\omega_1)P(x|\omega_1) + \lambda_{21}P(\omega_2)P(x|\omega_2)$$

$$l_2 = \lambda_{12}P(\omega_1)P(x|\omega_1) + \lambda_{22}P(\omega_2)P(x|\omega_2)$$

Όριο απόφασης:

$$l_1 = l_2 \iff$$

$$\lambda_{11}P(\omega_1)P(x|\omega_1) + \lambda_{21}P(\omega_2)P(x|\omega_2) = \lambda_{12}P(\omega_1)P(x|\omega_1) + \lambda_{22}P(\omega_2)P(x|\omega_2)$$

και επειδή $\lambda_{11} = \lambda_{22} = 0$:

$$\lambda_{21}P(\omega_2)P(x|\omega_2) = \lambda_{12}P(\omega_1)P(x|\omega_1)$$

$P(\omega_1) = P(\omega_2)$:

$$\lambda_{21}P(x|\omega_2) = \lambda_{12}P(x|\omega_1) \iff$$

$$1 \cdot \frac{x}{2^2} \cdot e^{-\frac{x^2}{2 \cdot 2^2}} = \frac{1}{2} \cdot \frac{x}{1^2} \cdot e^{-\frac{x^2}{2 \cdot 1^2}} \iff \frac{x}{4} \cdot e^{-\frac{x^2}{8}} = \frac{1}{2} \cdot x \cdot e^{-\frac{x^2}{2}} \iff x \cdot e^{-\frac{x^2}{8}} = 2x \cdot e^{-\frac{x^2}{2}} \iff$$

$$x \cdot e^{-\frac{x^2}{8}} - 2x \cdot e^{-\frac{x^2}{2}} = 0 \iff x \cdot (e^{-\frac{x^2}{8}} - 2 \cdot e^{-\frac{x^2}{2}}) = 0 \iff$$

$$\boxed{x = 0}$$

ή

$$e^{-\frac{x^2}{8}} = 2 \cdot e^{-\frac{x^2}{2}} \iff \ln(e^{-\frac{x^2}{8}}) = \ln(2 \cdot e^{-\frac{x^2}{2}}) \iff -\frac{x^2}{8} = \ln 2 + (-\frac{x^2}{2}) \iff \frac{x^2}{2} - \frac{x^2}{8} = \ln 2 \iff$$

$$\frac{3x^2}{8} = \ln 2 \iff x = \sqrt{\frac{8 \ln 2}{3}} \iff \boxed{x = \pm 1.359}$$